

Projet 1 : Classification des sentiments des textes en Darija

Description :

Ce projet vise à développer un système capable de **classer automatiquement le sentiment d'un texte écrit en Darija (dialecte algérien)**, en le catégorisant comme **positif** ou **négatif**.

Le Darija, étant un dialecte principalement oral et souvent transcrit de manière phonétique, présente des défis particuliers pour le **traitement automatique du langage naturel (NLP)**, notamment l'absence de normes orthographiques et la grande variété des expressions utilisées.

Le **jeu de données (dataset)** utilisé dans ce projet a été téléchargé à partir du site suivant :

<https://ranim-for-nlp.web.app/>

Les étapes du projet sont les suivantes :

a. Chargement des données :

Récupérer le contenu des publications à partir du fichier fourni.

b. Nettoyage des données :

Nettoyer le contenu textuel en supprimant les mots vides (stop words), la ponctuation et en appliquant des techniques de racinisation (stemming).

c. Modélisation :

Utilisation de modèles de représentation de texte, testant des méthodes classiques telles que **TF-IDF**, ou des **modèles pré-entraînés** sur le dialecte algérien, comme **DziriBERT**, spécifiquement adapté au Darija algérien.

d. Partitionnement des données :

Diviser le dataset en **80 % pour l'entraînement** et **20 % pour le test**.

e. Test et évaluation du modèle :

Trois options sont possibles pour l'évaluation, choisissez l'une d'elle :

- Utiliser l'ensemble de test comme ensemble de requêtes et l'ensemble d'entraînement comme corpus, calculer la similarité entre les deux, puis évaluer les résultats à l'aide des métriques appropriées. L'algorithme **KNN** peut être introduit aussi à ce niveau.

- Pour ceux qui maîtrisent le **machine learning**, entraîner un modèle sur l'ensemble d'entraînement et l'évaluer à l'aide de métriques telles que la **précision**, le **rappel (recall)** disponibles dans **scikit-learn**.
- Analyse exploratoire par visualisation :
 - Trouver la taille du vocabulaire.
 - Afficher un histogramme des différentes fréquences des mots dans le corpus global, ainsi que dans l'ensemble d'entraînement et l'ensemble de test.
 - Visualiser les mots les plus fréquents dans l'ensemble des phrases à sentiment négatif, ainsi que ceux correspondant aux phrases à sentiment positif.
 - Explorer d'autres aspects des données en proposant des visualisations alternatives pour mieux comprendre le corpus.